

Fecha: 03/10/2025

Nombre y apellido:

Legajo o DNI:

1) (20 ptos.)


Dada la siguiente matriz de confusión calcular: (para cada calculo especifique la formula aplicada)

	Largo	Corto
Largo	120	5
Corto	8	210

- Exactitud o Accuracy.
- True Positive Rate (TPR, Recall o Sensitivity).
- Explique que significa la medida de evaluación: Exactitud o Accuracy.

2) (20 ptos.)

Dado el siguiente conjunto de semillas:



- Grafique como quedarían las zonas iniciales para 5 grupos si se aplicara el algoritmo K-medias para clusterizar.
- Explique brevemente en que idea se basa K-medias para encontrar las zonas de los diferentes clusters.
- ¿Como debe ser el dataset para poder aplicar el algoritmo K-medias?

3) (20 ptos.)

Dado el siguiente conjunto de reglas de decisión:

- IF LONGITUD = 'Mediana' THEN **SI**
 - IF LONGITUD = 'Larga' AND PINTADA = 'Sí' THEN **SI**
 - IF LONGITUD = 'Larga' AND PINTADA = 'No' THEN **NO**
 - IF LONGITUD = 'Chica' THEN **NO**
- a) Grafique el TDIDT correspondiente tomando como raíz el atributo LONGITUD.
- b) Explique en términos generales cuales son las partes constitutivas de dicho árbol.
- c) Según el algoritmo J48 ¿Qué técnica se utiliza para determinar los atributos que forman parte del árbol que se intenta construir? Explique.

4) (20 ptos.)

Dado el siguiente dataset:

X1	X1 escalado
5	
98	
6	
200	

- a) Escale sus datos aplicando un StandarScaler (especifique la formula aplicada)

◦ Recuerde que :

$$\mu = \frac{1}{N} \cdot \sum_{i=1}^N x_i$$
$$\sigma = \sqrt{\frac{1}{N} \cdot \sum_{i=1}^N (x_i - \mu)^2}$$

- b) ¿En cual grupo de algoritmos de los vistos conviene aplicar el StandarScaler?

5) (20 ptos.)

Explique con sus palabras y describa:

- a) El algoritmo EM.
- b) ¿Cuales son las principales características de EM?
- c) Si se aplica el algoritmo EM a un conjunto de datos normalizados para dividir dicho conjunto total en 2 grupos y se obtiene finalmente lo siguiente:
- Cluster 1: media de 0,38 y desviación estándar de 0,1
 - Cluster 2: media de 0,37 y desviación estándar de 0,001
 - ¿Cual cluster parece "agrupar" mejor a los datos? ¿Por qué?